



UNIVERSIDAD DE LAS FUERZAS ARMADAS ESPE

LECTURA Y ESCRITURA DE TEXTOS ACADÉMICOS

DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN

RSL - Predicción del Tipo de Amenaza Cibernética mediante Algoritmos de Machine Learning

Estudiantes:

César Loor, Josué Merino, Alejandro Toscano

Docente:

Ing. Nancy Betancourt

Índice general

1. Planificación	6
1.1. Población	6
1.2. Procedimiento	6
1.3. Factores de importancia	6
1.4. Contexto	7
2. Justificación	8
3. Preguntas de Investigación	9
4. Protocolo de Revisión	10
4.1. Fuentes de Información	10
4.2. Estrategias de Búsqueda	10
4.3. Criterios de Inclusión	11
4.4. Criterios de Exclusión	11
4.5. Método de Extracción de Datos	12
4.6. Método de Evaluación de Calidad	12
5. Resultados	13
5.1. Automating Cybersecurity with Machine Learning and Predictive Analytics	13
5.2. The Role of Machine Learning in Cybersecurity	15
5.3. Cybersecurity Threats and Their Mitigation Approaches Using Ma- chine Learning	16
5.4. Ciberseguridad y uso de las TIC en el Sector Salud	18

5.5.	Desarrollo de un modelo predictivo basado en técnicas de Machine Learning para la priorización de vulnerabilidades y la optimización en la etapa de mitigación de riesgos operativos de ciberseguridad . . .	19
5.6.	Machine Learning and Deep Learning Approaches for CyberSecurity: A Review	21
5.7.	Cyberattacks, cyber threats, and attitudes toward cybersecurity policies	22
5.8.	Classification of Cybersecurity Threats, Vulnerabilities and Countermeasures in Database Systems	23
5.9.	Application of classification algorithms of Machine learning in cybersecurity	25
5.10.	Resilient Machine Learning for Networked Cyber Physical Systems: A Survey for Machine Learning Security to Securing Machine Learning for CPS	26
5.11.	Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application	28
5.12.	Machine Learning Algorithm for Malware Detection: Taxonomy, Current Challenges, and Future Directions	30
5.13.	An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks	31
5.14.	Estrategias de Ciberseguridad para Hogares Inteligentes: Una Revisión Sistemática de Amenazas y Enfoques de Mitigación en Entornos IoT	33
5.15.	A Comprehensive Survey: Evaluating the Efficiency of Artificial Intelligence and Machine Learning Techniques on Cyber Security Solutions	35
5.16.	Cyber Security Threats Detection in Internet of Things Using Deep Learning Approach	36
6.	Discusión	39
6.1.	Algoritmos de Machine Learning Predominantes y su Efectividad . .	39
6.2.	Características Más Predictivas	40
6.3.	Conjuntos de Datos Disponibles	40
6.4.	Métricas de Evaluación	40
6.5.	Desafíos y Oportunidades Futuras	41

Índice de Tablas

3.1. Preguntas de investigación	9
4.1. Tabla de extracción de datos del estudio	12
4.2. Métricas para la evaluación de calidad del estudio	12
5.1. Resumen de extracción de datos del estudio: Automating Cybersecurity with Machine Learning and Predictive Analytics	14
5.2. Evaluación de calidad del estudio: Automating Cybersecurity with Machine Learning and Predictive Analytics	14
5.3. Resumen de extracción de datos del estudio: The Role of Machine Learning in Cybersecurity	15
5.4. Evaluación de calidad del estudio: The Role of Machine Learning in Cybersecurity	16
5.5. Resumen de extracción de datos del estudio: Cybersecurity Threats and Their Mitigation Approaches Using Machine Learning	17
5.6. Evaluación de calidad del estudio: Cybersecurity Threats and Their Mitigation Approaches Using Machine Learning	17
5.7. Resumen de extracción de datos del estudio: Ciberseguridad y uso de las TIC en el Sector Salud	18
5.8. Evaluación de calidad del estudio: Ciberseguridad y uso de las TIC en el Sector Salud	19
5.9. Resumen de extracción de datos del estudio: Desarrollo de un modelo predictivo basado en técnicas de Machine Learning para la priorización de vulnerabilidades y la optimización en la etapa de mitigación de riesgos operativos de ciberseguridad	20

5.10. Evaluación de calidad del estudio: Desarrollo de un modelo predictivo basado en técnicas de Machine Learning para la priorización de vulnerabilidades y la optimización en la etapa de mitigación de riesgos operativos de ciberseguridad	20
5.11. Resumen de extracción de datos del estudio: Machine Learning and Deep Learning Approaches for CyberSecurity: A Review	21
5.12. Evaluación de calidad del estudio: Machine Learning and Deep Learning Approaches for CyberSecurity: A Review	22
5.13. Resumen de extracción de datos del estudio: Cyberattacks, cyber threats, and attitudes toward cybersecurity policies	23
5.14. Evaluación de calidad del estudio: Cyberattacks, cyber threats, and attitudes toward cybersecurity policies	23
5.15. Resumen de extracción de datos del estudio: Classification of Cybersecurity Threats, Vulnerabilities and Countermeasures in Database Systems	24
5.16. Evaluación de calidad del estudio: Classification of Cybersecurity Threats, Vulnerabilities and Countermeasures in Database Systems . . .	25
5.17. Resumen de extracción de datos del estudio: Application of classification algorithms of Machine learning in cybersecurity	26
5.18. Evaluación de calidad del estudio: Application of classification algorithms of Machine learning in cybersecurity	26
5.19. Resumen de extracción de datos del estudio: Resilient Machine Learning for Networked Cyber Physical Systems: A Survey for Machine Learning Security to Securing Machine Learning for CPS	27
5.20. Evaluación de calidad del estudio: Resilient Machine Learning for Networked Cyber Physical Systems: A Survey for Machine Learning Security to Securing Machine Learning for CPS	28
5.21. Resumen de extracción de datos del estudio: Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application	29
5.22. Evaluación de calidad del estudio: Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application	29

5.23. Resumen de extracción de datos del estudio: Machine Learning Algorithm for Malware Detection: Taxonomy, Current Challenges, and Future Directions	30
5.24. Evaluación de calidad del estudio: Machine Learning Algorithm for Malware Detection: Taxonomy, Current Challenges, and Future Directions	31
5.25. Resumen de extracción de datos del estudio: An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks	32
5.26. Evaluación de calidad del estudio: An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks	32
5.27. Resumen de extracción de datos del estudio: Estrategias de Ciberseguridad para Hogares Inteligentes: Una Revisión Sistemática de Amenazas y Enfoques de Mitigación en Entornos IoTs	33
5.28. Evaluación de calidad del estudio: Estrategias de Ciberseguridad para Hogares Inteligentes: Una Revisión Sistemática de Amenazas y Enfoques de Mitigación en Entornos IoTs	34
5.29. Resumen de extracción de datos del estudio: A Comprehensive Survey: Evaluating the Efficiency of Artificial Intelligence and Machine Learning Techniques on Cyber Security Solutions	35
5.30. Evaluación de calidad del estudio: A Comprehensive Survey: Evaluating the Efficiency of Artificial Intelligence and Machine Learning Techniques on Cyber Security Solutions	36
5.31. Resumen de extracción de datos del estudio: Cyber Security Threats Detection in Internet of Things Using Deep Learning Approach . . .	37
5.32. Evaluación de calidad del estudio: Cyber Security Threats Detection in Internet of Things Using Deep Learning Approach	38

1. Planificación

Pregunta: ¿Qué tan eficaz es un modelo de clasificación para predecir el tipo de amenaza cibernética en función de las características del incidente?

Hipótesis: Un modelo de clasificación entrenado con características como industria, fuente del ataque y vulnerabilidad puede predecir con alta precisión el tipo de amenaza cibernética.

1.1. Población

El proceso se lo realizará al área de aplicación: Ciberseguridad, Machine Learning y Ciencias de la Computación.

1.2. Procedimiento

Utilización de algoritmos de machine learning que estén optimizados para el contexto. A través de herramientas como Google Collab mediante la utilización del lenguaje de programación Python.

1.3. Factores de importancia

Los factores de importancia dentro del dataset son los siguientes:

- País
- Año
- Tipo de ataque

- Sector objetivo
- Pérdida financiera (en millones de dólares)
- Número de usuarios afectados
- Origen del ataque
- Tipo de vulnerabilidad de seguridad
- Mecanismo de defensa utilizado
- Tiempo de resolución del incidente (en horas)

1.4. Contexto

Se toma datos de las industrias como:

- Banco
- Educación
- Gobierno
- Salud
- IT
- Minoristas
- Telecomunicaciones

2. Justificación

Existen muchas investigaciones sobre el uso de algoritmos de aprendizaje automático para predecir amenazas cibernéticas, pero no hay un acuerdo claro sobre cuál es el mejor enfoque, debido a esto es necesario realizar una RSL (Revisión Sistemática de la Literatura). Esta revisión nos permitirá reunir, analizar y comparar los estudios más relevantes realizados entre 2015 y 2024, con el fin de entender mejor qué modelos se están utilizando, qué datos se consideran más útiles, qué características del ataque son más predictivas y cómo se evalúa el rendimiento de estos modelos.

Realizar una RSL es importante porque nos ayuda a identificar patrones, vacíos en el conocimiento y posibles mejoras para futuras investigaciones en el campo de la ciberseguridad. Además, servirá como una base sólida para quienes quieran desarrollar herramientas más eficaces para la detección y prevención de amenazas cibernéticas usando inteligencia artificial.

3. Preguntas de Investigación

Código	Pregunta de Investigación
RQ1	¿Qué tipos de amenazas cibernéticas son más comunes?
RQ2	¿Cómo se categorizan los tipos de amenazas cibernéticas?
RQ3	¿Qué atributos de un incidente cibernético tienen mayor influencia en la predicción del tipo de amenaza?
RQ4	¿Qué algoritmos de clasificación son más efectivos para identificar amenazas cibernéticas?
RQ5	¿Qué conjuntos de datos están disponibles para entrenar y evaluar modelos de predicción de amenazas cibernéticas?
RQ6	¿Qué métricas se utilizan comúnmente para evaluar la eficacia de un modelo de clasificación en ciberseguridad?

Cuadro 3.1: Preguntas de investigación

4. Protocolo de Revisión

4.1. Fuentes de Información

Los motores de búsqueda utilizados para la revisión de literatura son los siguientes:

- Scopus
- IEEE Xplore

4.2. Estrategias de Búsqueda

Las cadenas de búsqueda utilizadas serán las siguientes:

- (“cyber threat” OR “cyber attack”) AND (“classification model” OR “machine learning” OR “ML”) AND (“prediction” OR “detection”)
- (“cyber threat” OR “cyber attack”) AND (“prediction” OR “detection”) AND (“machine learning” OR “ML”)
- (“cyber threat prediction”) AND (“industry” OR “sector”) AND (“vulnerability” OR “attack source”) AND (“machine learning”)
- (“cyber threat type” OR “cyber attack type”) AND (“prediction” OR “classification”) AND (“machine learning”)
- (“cybersecurity threats”) AND (“data analysis” OR “data mining”) AND (“machine learning algorithms”)
- (“threat intelligence”) AND (“cyber attack classification”) AND (“supervised learning” OR “unsupervised learning”)

- (“cyber threat detection”) AND (“deep learning” OR “neural networks”) AND (“attack type classification”)
- (“cyber incident” OR “cyber breach”) AND (“risk prediction”) AND (“machine learning techniques”)

4.3. Criterios de Inclusión

- Artículos publicados entre 2015 y 2024
- Lenguajes: Inglés y Español
- Aplicación de Algoritmos de Machine Learning
- Campo: Ciencias de la Computación, Ciberseguridad y Machine Learning
- Estudios revisados por pares (peer-reviewed)
- Documentos donde se hable de la industria: Banco, Educación, Gobierno, Salud, IT, Minoristas, Telecomunicaciones

4.4. Criterios de Exclusión

- Documentos que excedan las quince páginas
- Artículos sin acceso al texto completo.
- Artículos y documentos de pago

4.5. Método de Extracción de Datos

Elemento	Descripción
Autores y Año	
Algoritmos Utilizados	
Dataset	
Variables Utilizadas	
Métricas de Evaluación	
Resultados Principales	
Limitaciones	

Cuadro 4.1: Tabla de extracción de datos del estudio

4.6. Método de Evaluación de Calidad

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	
¿Describe adecuadamente el algoritmo y los datos?	
¿Reporta métricas de rendimiento confiables?	
¿Analiza resultados o simplemente los menciona?	
Puntaje Total	

Cuadro 4.2: Métricas para la evaluación de calidad del estudio

5. Resultados

Se muestra un resumen claro y organizado de los estudios seleccionados que forman parte del estado del arte. Se utilizaron tablas (extracción de datos y evaluación de calidad) para extraer los datos más relevantes de cada uno, como los algoritmos usados, datasets, variables analizadas, métricas de evaluación, resultados obtenidos y limitaciones encontradas. Además, se incluye una evaluación de calidad para cada estudio, basada en ciertos criterios básicos que permiten identificar qué tan completos y útiles son en el contexto del presente trabajo. Esto permite comparar enfoques y tener una mejor idea del panorama actual en el uso de Machine Learning dentro de la Ciberseguridad.

5.1. Automating Cybersecurity with Machine Learning and Predictive Analytics

Elemento	Descripción
Título del Estudio	Automating Cybersecurity with Machine Learning and Predictive Analytics
Autores y Año	Hunter Joshua et al., 2024
Algoritmos Utilizados	Random Forest, K-means
Dataset	No menciona
Variables Utilizadas	Pérdidas Económicas por Ataques Cibernéticos
Métricas de Evaluación	No hay

Elemento	Descripción
Resultados Principales	Machine Learning enfrenta retos en ciberseguridad, especialmente en bases de datos de programas antivirus. Se destaca la importancia del aprendizaje continuo asistido para mantener medidas proactivas, en contraste con las reactivas más comunes.
Limitaciones	Falta del dataset, implementación de algoritmos poco clara, y ausencia de métricas de rendimiento confiables.

Cuadro 5.1: Resumen de extracción de datos del estudio: Automating Cybersecurity with Machine Learning and Predictive Analytics

Este estudio destaca la importancia del aprendizaje continuo asistido como una medida proactiva frente a los ataques cibernéticos, aunque también señala limitaciones significativas en la falta de datasets robustos y métricas de evaluación claras.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	0
¿Analiza resultados o simplemente los menciona?	0
Puntaje Total	2

Cuadro 5.2: Evaluación de calidad del estudio: Automating Cybersecurity with Machine Learning and Predictive Analytics

5.2. The Role of Machine Learning in Cybersecurity

Elemento	Descripción
Título del Estudio	The Role of Machine Learning in Cybersecurity
Autores y Año	Giovanni Apruzzese, Pavel Laskov, Edgardo Montes de Oca, Wissam Mallouli, Luis Brdalo Rapa, Athanasios Vasileios Grammatopoulos, Fabio Di Franco , 2023
Algoritmos Utilizados	Supervisados, no supervisados (BNC), profundos (LSTM), por refuerzo, estadísticos (SARIMA).
Dataset	Casos de estudio: datos de NDN y tráfico de ICS.
Variables Utilizadas	Tráfico de red, características de malware, contenido web/email, logs, telemetría industrial.
Métricas de Evaluación	Acc, DR/TPR, FPR, Precision, F1. Casos de estudio: TPR, FPR.
Resultados Principales	Análisis exhaustivo de beneficios, problemas y futuro de ML en ciberseguridad. Identifica concepciones erróneas. Propone desafíos (certificación, datos, investigación, orquestación) para cerrar brecha investigación-práctica. Presenta dos casos de estudio industriales (NDN, ICS).
Limitaciones	Confidencialidad/disponibilidad de datos, brecha investigación-práctica.

Cuadro 5.3: Resumen de extracción de datos del estudio: The Role of Machine Learning in Cybersecurity

Este estudio exhaustivo resalta el potencial del ML en todo el espectro de la ciberseguridad, pero enfatiza desafíos críticos como la disponibilidad de datos realistas, la adaptación a entornos adversariales y la necesidad de cerrar la brecha entre investigación y aplicación práctica.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	4

Cuadro 5.4: Evaluación de calidad del estudio: The Role of Machine Learning in Cybersecurity

5.3. Cybersecurity Threats and Their Mitigation Approaches Using Machine Learning

Elemento	Descripción
Título del Estudio	Cybersecurity Threats and Their Mitigation Approaches Using Machine Learning
Autores y Año	Mostofa Ahsan, Kendall E. Nygard, Rahul Gomes, Md Minhaz Chowdhury, Nafiz Rifat, Jayden F Connolly, 2022
Algoritmos Utilizados	Supervisados (SVM, Naive Bayes, Árboles de Decisión, RF), no supervisados (K-Means, DBSCAN, a priori), profundos (ANN, DBN, CNN, RNN), y de refuerzo (DQN)
Dataset	Datasets públicos no especificados
Variables Utilizadas	Tráfico de red, logs, atributos de malware, datos de correo electrónico
Métricas de Evaluación	Accuracy, False Positive Rate (FPR), False Acceptance Rate (FAR), Error Rate

Elemento	Descripción
Resultados Principales	Revisión de técnicas de ML para mitigar amenazas. Clasifica amenazas, discute algoritmos y datasets usados, y el rol del ML en fases del ciberataque. Aborda desafíos como disponibilidad de datos y propone futuras líneas como aprendizaje híbrido, HE y computación cuántica.
Limitaciones	Disponibilidad y calidad de datasets

Cuadro 5.5: Resumen de extracción de datos del estudio: Cybersecurity Threats and Their Mitigation Approaches Using Machine Learning

Este estudio de revisión ofrece una amplia panorámica de cómo diversas técnicas de Machine Learning se aplican para contrarrestar amenazas de ciberseguridad, al tiempo que identifica desafíos cruciales como la calidad y disponibilidad de los datasets y la necesidad de abordar problemas emergentes como el data leakage y las implicaciones de la computación cuántica.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	4

Cuadro 5.6: Evaluación de calidad del estudio: Cybersecurity Threats and Their Mitigation Approaches Using Machine Learning

5.4. Ciberseguridad y uso de las TIC en el Sector Salud

Elemento	Descripción
Título del Estudio	Ciberseguridad y uso de las TIC en el Sector Salud
Autores y Año	A Cervera , A Goussens, 2024
Algoritmos Utilizados	No utiliza
Dataset	No utiliza
Variables Utilizadas	No utiliza
Métricas de Evaluación	No aplica
Resultados Principales	Análisis de amenazas cibernéticas en el sector salud, su impacto en la confidencialidad, integridad y disponibilidad (CIA), discusión de las implicaciones bioéticas y propuesta de un modelo de ciberseguridad basado en políticas, tecnologías y concienciación del personal.
Limitaciones	El estudio es una discusión conceptual y no presenta un algoritmo de ML específico, una implementación detallada, ni un dataset público que permita su replicación o validación directa para una aplicación de ML. El estudio está enfocado únicamente a la industria de la salud, puede servir como consulta ya que el dataset utilizado para el artículo que se escribirá tiene como variable la industria de la salud.

Cuadro 5.7: Resumen de extracción de datos del estudio: Ciberseguridad y uso de las TIC en el Sector Salud

Este artículo destaca la creciente vulnerabilidad del sector salud a ciberataques, subrayando las graves consecuencias éticas y operativas, y aboga por un modelo de ciberseguridad integral que combine políticas robustas, tecnología avanzada y una

sólida cultura de concienciación.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	0
¿Reporta métricas de rendimiento confiables?	0
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	2

Cuadro 5.8: Evaluación de calidad del estudio: Ciberseguridad y uso de las TIC en el Sector Salud

5.5. Desarrollo de un modelo predictivo basado en técnicas de Machine Learning para la priorización de vulnerabilidades y la optimización en la etapa de mitigación de riesgos operativos de ciberseguridad

Elemento	Descripción
Título del Estudio	Desarrollo de un modelo predictivo basado en técnicas de Machine Learning para la priorización de vulnerabilidades y la optimización en la etapa de mitigación de riesgos operativos de ciberseguridad
Autores y Año	Camasca Huaman, Jhonatan Cristobal; Gave Cardenas, Kevin Paredes; Paredes Castro, Patricia Jackeline, 2024
Algoritmos Utilizados	K-Means y BIRCH

Elemento	Descripción
Dataset	Creación de conjunto de datos a partir de los escaneos de vulnerabilidades proporcionados por la empresa ABC S.A.C. Complementado con reportes descriptivos y puntuaciones de explotabilidad.
Variables Utilizadas	Priorización de la vulnerabilidad, Reportes de escaneos de vulnerabilidades, reportes de probabilidad de explotación de vulnerabilidades (EPSS)
Métricas de Evaluación	Precisión, Recall, F1-Score y Accuracy.
Resultados Principales	Los resultados muestran que Random Forest, en combinación con BIRCH, alcanzó una precisión del 98 %, mejorando significativamente la optimización del proceso de Gestión de Vulnerabilidades y fortaleciendo la ciberseguridad en entornos empresariales digitalizados.
Limitaciones	Contenido extenso

Cuadro 5.9: Resumen de extracción de datos del estudio: Desarrollo de un modelo predictivo basado en técnicas de Machine Learning para la priorización de vulnerabilidades y la optimización en la etapa de mitigación de riesgos operativos de ciberseguridad

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	0
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	0
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	2

Cuadro 5.10: Evaluación de calidad del estudio: Desarrollo de un modelo predictivo basado en técnicas de Machine Learning para la priorización de vulnerabilidades y la optimización en la etapa de mitigación de riesgos operativos de ciberseguridad

5.6. Machine Learning and Deep Learning Approaches for CyberSecurity: A Review

Elemento	Descripción
Título del Estudio	Machine Learning and Deep Learning Approaches for CyberSecurity: A Review
Autores y Año	Asmaa Halbouni, Teddy Surya Gunawan, Mohamed Hadi Habaebi, Murad Halbouni, Mira Kartiwi, Robiah Ahmad, 2022
Algoritmos Utilizados	Algoritmos supervisados (SVM, RF, Naive Bayes, Árbol de Decisión), no supervisados, y profundos (AE, CNN, RNN, LSTM, DBN, GRU). También híbridos.
Dataset	KDD Cup 1999, UNSW-IDS15, CIC-IDS2017, NSL-KDD, PU-IDS, ISCX2012, DARPA, Kyoto, WSN-DS, CIDDS-001.
Variables Utilizadas	Información de conexiones TCP, tráfico de red, y características abstractas de comportamiento de usuarios.
Métricas de Evaluación	Accuracy, Recall, Precision, F1-Score, False Positive Rate (FPR).
Resultados Principales	Compara enfoques, clasificaciones de ataques, datasets y métricas. Analiza trabajos recientes y concluye que DL supera a ML en precisión y tasa de falsas alarmas para problemas complejos, aunque presenta desafíos.
Limitaciones	Mayor tiempo para contextualizar y entender debido a barrera lingüística y longitud de documento.

Cuadro 5.11: Resumen de extracción de datos del estudio: Machine Learning and Deep Learning Approaches for CyberSecurity: A Review

Este estudio de revisión ofrece una visión general de la aplicación de Machine Learning y Deep Learning en Sistemas de Detección de Intrusos, destacando la evolución hacia enfoques de DL por su mayor precisión, aunque señala desafíos persistentes como la disponibilidad de datasets actualizados y el ajuste de hiperparámetros.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	4

Cuadro 5.12: Evaluación de calidad del estudio: Machine Learning and Deep Learning Approaches for CyberSecurity: A Review

5.7. Cyberattacks, cyber threats, and attitudes toward cybersecurity policies

Elemento	Descripción
Título del Estudio	Cyberattacks, cyber threats, and attitudes toward cybersecurity policies
Autores y Año	Keren L.G. Snider, Ryan Shandler, Shay Zandani, Daphna Canetti (2021)
Algoritmos Utilizados	No aplica. Estudio basado en experimento controlado aleatorio con encuestas
Dataset	1022 participantes israelíes, asignados aleatoriamente a grupos de tratamiento y control
Variables Utilizadas	Tipo de exposición (letal, no letal, control), percepción de amenaza, apoyo a políticas de ciberseguridad (CPP, CAP, COP), variables sociodemográficas

Elemento	Descripción
Métricas de Evaluación	ANOVA, análisis de mediación (path analysis), coeficientes estandarizados beta, alfa de Cronbach
Resultados Principales	La exposición a ciberataques (letal o no letal) incrementa el apoyo a políticas de ciberseguridad, mediado por la percepción de amenaza. Ataques letales inducen mayor apoyo a políticas de alerta (CAP), mientras que ataques no letales inducen más apoyo a políticas de supervisión (COP)
Limitaciones	Falta de evidencia sobre la duración del efecto; muestra limitada geográficamente a Israel; exposición solo a reportes iniciales; no incluye identidades de atacantes

Cuadro 5.13: Resumen de extracción de datos del estudio: Cyberattacks, cyber threats, and attitudes toward cybersecurity policies

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	0
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	3/4

Cuadro 5.14: Evaluación de calidad del estudio: Cyberattacks, cyber threats, and attitudes toward cybersecurity policies

5.8. Classification of Cybersecurity Threats, Vulnerabilities and Countermeasures in Database Systems

Elemento	Descripción
Título del Estudio	Classification of Cybersecurity Threats, Vulnerabilities and Countermeasures in Database Systems
Autores y Año	Mohammed Amin Almaiah, Leen Mohammad Saqr, Leen Ahmad Al-Rawwash, Layan Ahmed Attellawi, Romel Al-Ali, Omar Almomani, 2024
Algoritmos Utilizados	No menciona algoritmos específicos de machine learning. Se enfoca en métodos de análisis de contenido para clasificar amenazas, vulnerabilidades y contramedidas.
Dataset	No menciona un dataset específico. El estudio utiliza datos recopilados a partir de revisiones bibliográficas y análisis de literatura existente sobre amenazas cibernéticas en sistemas de bases de datos.
Variables Utilizadas	- Tipos de amenazas (técnicas y no técnicas). - Vulnerabilidades técnicas y no técnicas. - Contramedidas para mitigar riesgos.
Métricas de Evaluación	No menciona métricas de evaluación cuantitativas. El estudio se basa en un análisis cualitativo de las amenazas, vulnerabilidades y contramedidas.
Resultados Principales	Las amenazas más comunes son: ataques de inyección SQL (9 %), ataques de denegación de servicio (DoS) (9 %), auditorías vulnerables (7 %), intentos de intrusión (7 %) y ransomware (5 %).
Limitaciones	- No utiliza algoritmos de machine learning para predecir o clasificar amenazas. - El estudio se basa en revisiones bibliográficas y análisis cualitativos, lo que limita la generalización de los resultados.

Cuadro 5.15: Resumen de extracción de datos del estudio: Classification of Cybersecurity Threats, Vulnerabilities and Countermeasures in Database Systems

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	0
¿Reporta métricas de rendimiento confiables?	0
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	2/4

Cuadro 5.16: Evaluación de calidad del estudio: Classification of Cybersecurity Threats, Vulnerabilities and Countermeasures in Database Systems

5.9. Application of classification algorithms of Machine learning in cybersecurity

Elemento	Descripción
Título del Estudio	Application of classification algorithms of Machine learning in cybersecurity
Autores y Año	Gunay Abdiyeva-Aliyeva, Jeyhun Aliyev, Ulfat Sadigov (2022)
Algoritmos Utilizados	XGBoost, Random Forest, Neural Network, Logistic Regression, ADA Booster, SVM
Dataset	Phishing website dataset (6157 sitios legítimos y 4898 sitios de phishing), UNB NSK KDD dataset (2540044 registros con 49 características)
Variables Utilizadas	IP address, URL length, redirect symbol in URL, prefix and suffix of the domain, anchor URL refer to another domain, containing @ symbol in the URL, abnormal URL, subdomains, favicon, external request, entre otras
Métricas de Evaluación	Accuracy, Precision, Recall, F1 score

Elemento	Descripción
Resultados Principales	- XGBoost obtuvo 98 % accuracy y 98.7 % precision en detección de phishing - En NIDS, XGBoost alcanzó AUC de 0.99 - XGBoost mostró mejor rendimiento y velocidad en comparación con otros algoritmos
Limitaciones	- No se discuten en detalle las limitaciones del estudio - Se requiere reentrenamiento constante debido a nuevas técnicas de ataque

Cuadro 5.17: Resumen de extracción de datos del estudio: Application of classification algorithms of Machine learning in cybersecurity

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	4

Cuadro 5.18: Evaluación de calidad del estudio: Application of classification algorithms of Machine learning in cybersecurity

5.10. Resilient Machine Learning for Networked Cyber Physical Systems: A Survey for Machine Learning Security to Securing Machine Learning for CPS

Elemento	Descripción
Título del Estudio	Resilient Machine Learning for Networked Cyber Physical Systems: A Survey for Machine Learning Security to Securing Machine Learning for CPS
Autores y Año	Felix O. Olowononi, Danda B. Rawat, Chunmei Liu (2020)
Algoritmos Utilizados	Deep Learning, Reinforcement Learning, Generative Adversarial Networks (GAN), Redes Neuronales Profundas (DNN), Q-Learning, Deep Q-Network (DQN), entre otros
Dataset	No se menciona un dataset específico. Se hace referencia al uso de datos generados por sensores en sistemas CPS
Variables Utilizadas	Datos de sensores, señales de control, mediciones físicas, estados del sistema, acciones del agente, señales de recompensa
Métricas de Evaluación	Precisión, robustez, capacidad de detección de anomalías, efectividad en la generación de ejemplos adversarios, capacidad de recuperación ante ataques
Resultados Principales	- El aprendizaje profundo es efectivo para modelar sistemas complejos - Los GAN pueden ser usados tanto para ataques como para defensa - La combinación de métodos mejora la seguridad general del sistema
Limitaciones	- Falta de datasets estándar - Dificultad para evaluar en entornos del mundo real

Cuadro 5.19: Resumen de extracción de datos del estudio: Resilient Machine Learning for Networked Cyber Physical Systems: A Survey for Machine Learning Security to Securing Machine Learning for CPS

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	0
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	3/4

Cuadro 5.20: Evaluación de calidad del estudio: Resilient Machine Learning for Networked Cyber Physical Systems: A Survey for Machine Learning Security to Securing Machine Learning for CPS

5.11. Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application

Elemento	Descripción
Título del Estudio	Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application
Autores y Año	Tommaso Zoppi, Andrea Ceccarelli, Andrea Bon-davalli (2021)
Algoritmos Utilizados	Algoritmos no supervisados como k-means, SOM, LOF, HBOS, Isolation Forest, One-Class SVM, entre otros. También se emplea meta-aprendizaje (Bagging y Boosting).
Dataset	SDN20: Conjunto de datos reciente que incluye tráfico normal y cinco tipos de ataques (DDoS, DoS, Probe, U2R, BFA).
Variables Utilizadas	Características numéricas ordinales (p. ej., longitud de encabezado, tamaño promedio de paquetes), excluyendo características categóricas como IP y puerto.

Elemento	Descripción
Métricas de Evaluación	MCC (Matthews Correlation Coefficient), F2-Score, Precision, Recall, Matriz de Confusión (TP, TN, FP, FN).
Resultados Principales	- Los ensembles de Boosting superaron a los algoritmos no supervisados básicos.- COF con Boosting alcanzó valores excepcionales: Precision=0.997, Recall=0.994, F2-Score=0.995, MCC=0.986. - Robustez frente a ataques de día cero.
Limitaciones	La efectividad depende de la selección adecuada de características y parámetros. - No todos los ensembles mejoran el rendimiento (ej., Bagging de ODIN tuvo resultados inferiores a SDO).

Cuadro 5.21: Resumen de extracción de datos del estudio: Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	4/4

Cuadro 5.22: Evaluación de calidad del estudio: Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application

5.12. Machine Learning Algorithm for Malware Detection: Taxonomy, Current Challenges, and Future Directions

Elemento	Descripción
Título del Estudio	Machine Learning Algorithm for Malware Detection: Taxonomy, Current Challenges, and Future Directions
Autores y Año	Nor Zakiah Gorment, Ali Selamat, Lim Kok Cheng, Ondrej Krejcar (2023)
Algoritmos Utilizados	SVM, Decision Tree (DT), K-Nearest Neighbour (KNN), Naïve Bayes (NB), Bayesian, Gaussian, N-grams, K-Means, Meta-heurísticos, Neuro-Fuzzy
Dataset	VirusShare, DREBIN, Android Malware Genome Project, Google Play Store, EMBER 2018
Variables Utilizadas	Información general de archivos, cabecera PE, funciones importadas/exportadas, secciones, histogramas de bytes y entropía, información de cadenas
Métricas de Evaluación	Accuracy, Precision, Recall, F1-Score, ROC, True Positive Rate (TPR), False Positive Rate (FPR), False Negative Rate (FNR)
Resultados Principales	SVM, N-grams y DT mostraron hasta 100 % de precisión en conjuntos pequeños; en conjuntos grandes, SVM logró 98.62 %, N-gram 97.43 % y DT 96.49 %
Limitaciones	Conjuntos de datos pequeños o desactualizados, técnicas de ofuscación, alta tasa de falsos positivos, selección de características inadecuada

Cuadro 5.23: Resumen de extracción de datos del estudio: Machine Learning Algorithm for Malware Detection: Taxonomy, Current Challenges, and Future Directions

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	4/4

Cuadro 5.24: Evaluación de calidad del estudio: Machine Learning Algorithm for Malware Detection: Taxonomy, Current Challenges, and Future Directions

5.13. An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks

Elemento	Descripción
Título del Estudio	An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks
Autores y Año	J. Buuri, S. Mansour, M. El-Said, X Wang, 2024
Algoritmos Utilizados	Microsoft Azure automated machine learning (AutoML)
Dataset	No especifica
Variables Utilizadas	No especifica
Métricas de Evaluación	Precision, recall, F-measure, overall AutoML model accuracy
Resultados Principales	Evaluación de la precisión y efectividad de Azure AutoML para detectar anomalías de día cero, utilizando sus capacidades de aprendizaje dinámico y adaptación continua.

Elemento	Descripción
Limitaciones	No especifica los datasets utilizados ni los algoritmos concretos seleccionados por AutoML, lo que impide una replicación o comparación directa. No se detallan las características de los datos. Documento difícilmente accesible.

Cuadro 5.25: Resumen de extracción de datos del estudio: An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks

Este estudio se enfoca en utilizar las capacidades de aprendizaje dinámico de Microsoft Azure AutoML para mejorar la detección de ataques de día cero, aunque los detalles específicos sobre los datasets y modelos seleccionados no se proporcionan en el resumen.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	0
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	3

Cuadro 5.26: Evaluación de calidad del estudio: An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks

5.14. Estrategias de Ciberseguridad para Hogares Inteligentes: Una Revisión Sistemática de Amenazas y Enfoques de Mitigación en Entornos IoT

Elemento	Descripción
Título del Estudio	Estrategias de Ciberseguridad para Hogares Inteligentes: Una Revisión Sistemática de Amenazas y Enfoques de Mitigación en Entornos IoTs
Autores y Año	V. Vera, J Aquino, 2024
Algoritmos Utilizados	IDS basados en ML/ANN, CNN, FL
Dataset	No especifica
Variables Utilizadas	Tipos de ataque, estrategias de mitigación
Métricas de Evaluación	No aplica
Resultados Principales	Identifica tendencias de amenazas (ej. DDoS, Man-in-the-Middle) y estrategias de mitigación (ej. ML, blockchain, criptografía) en hogares inteligentes. Analiza 49 estudios (2020-2024), categoriza ataques y soluciones según la triada CID. Destaca alta precisión de soluciones ML (hasta 99.79%) y efectividad de blockchain.
Limitaciones	No presenta una implementación original de un algoritmo de ML ni un dataset. Los resultados se basan en la literatura existente seleccionada.

Cuadro 5.27: Resumen de extracción de datos del estudio: Estrategias de Ciberseguridad para Hogares Inteligentes: Una Revisión Sistemática de Amenazas y Enfoques de Mitigación en Entornos IoTs

Esta revisión sistemática ofrece una valiosa síntesis de las amenazas y estrategias de mitigación en hogares inteligentes, destacando la alta eficacia de soluciones basadas en Machine Learning y blockchain, y subraya la necesidad de enfoques integrales

que aborden la triada de seguridad CID.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	0
¿Reporta métricas de rendimiento confiables?	0
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	2

Cuadro 5.28: Evaluación de calidad del estudio: Estrategias de Ciberseguridad para Hogares Inteligentes: Una Revisión Sistemática de Amenazas y Enfoques de Mitigación en Entornos IoTs

5.15. A Comprehensive Survey: Evaluating the Efficiency of Artificial Intelligence and Machine Learning Techniques on Cyber Security Solutions

Elemento	Descripción
Título del Estudio	A Comprehensive Survey: Evaluating the Efficiency of Artificial Intelligence and Machine Learning Techniques on Cyber Security Solutions
Autores y Año	M. Ozkan, E. Akin, Ö. Aslan, S. Kosunalp, T. Iliev, I Stoyanov, Ivan Beloev, 2024
Algoritmos Utilizados	ML (supervisado, no supervisado, semi-supervisado, regresión, probabilísticos, SVM, árboles de decisión), DL (ANN, DNN, RNN, LSTM, RBM, DBN, CNN, SAE, GAN) y RL (Q-learning, DRL).
Dataset	Encuestas y Datasets de ciberseguridad comunes en la literatura que otros estudios utilizan
Variables Utilizadas	No aplica
Métricas de Evaluación	Accuracy, Precision, Recall, F-score, FAR
Resultados Principales	Encuesta exhaustiva que evalúa la eficiencia de ML, DL y RL en ciberseguridad (detección de malware/intrusiones, evaluación de vulnerabilidades). Analiza beneficios, limitaciones, desafíos (calidad de datos, interpretabilidad, ataques adversariales) y el uso de herramientas tipo ChatGPT en ciberseguridad.
Limitaciones	No especifica variables utilizadas

Cuadro 5.29: Resumen de extracción de datos del estudio: A Comprehensive Survey: Evaluating the Efficiency of Artificial Intelligence and Machine Learning Techniques on Cyber Security Solutions

Este estudio de encuesta ofrece una evaluación detallada de la eficiencia de diversas técnicas de IA (ML, DL, RL) en ciberseguridad, incluyendo el papel de herramientas como ChatGPT, pero como revisión, no proporciona un algoritmo o dataset nuevo para aplicación directa.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	1
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	4

Cuadro 5.30: Evaluación de calidad del estudio: A Comprehensive Survey: Evaluating the Efficiency of Artificial Intelligence and Machine Learning Techniques on Cyber Security Solutions

5.16. Cyber Security Threats Detection in Internet of Things Using Deep Learning Approach

Elemento	Descripción
Título del Estudio	Cyber Security Threats Detection in Internet of Things Using Deep Learning Approach
Autores y Año	F. Ullah, H. Naeem, S. Jabbar, S. Khalid, M. Ahsan Latif, F. Al-turjman, 2019
Algoritmos Utilizados	Deep Learning, DNN, DCNN, Optimizador Adam, funciones de activación ReLU y sigmoid.
Dataset	Piratería de software: Google Code Jam, Leopard Mobile dataset y Mailing Dataset
Variables Utilizadas	Tokens ponderados extraídos de código fuente. Imágenes a color generadas a partir de archivos binarios de malware.

Elemento	Descripción
Métricas de Evaluación	Accuracy, validation accuracy, loss, validation loss, F-measure, confusion matrix, tiempo computacional.
Resultados Principales	Propone una arquitectura de Deep Learning combinada para detectar amenazas de ciberseguridad (piratería de software y malware) en redes IoT. El método para piratería utiliza DNN con características de texto. El método para malware usa DCNN con visualización de imágenes. Reporta una accuracy del 97.46 % para la detección de malware, superando a métodos basados en GIST+SVM, LBP+SVM y CLGM+SVM.
Limitaciones	Aunque se nombran los datasets y los tipos de algoritmos, los detalles específicos de la arquitectura de las redes neuronales y el preprocesamiento exacto son de alto nivel, lo que podría dificultar una replicación precisa. Trabajo enfocado únicamente en la industria y en el campo del Internet of Things (IoT)

Cuadro 5.31: Resumen de extracción de datos del estudio: Cyber Security Threats Detection in Internet of Things Using Deep Learning Approach

Este estudio propone un enfoque combinado de Deep Learning (TensorFlow DNN y DCNN) para detectar piratería de software y malware en IoT, destacando una alta precisión en la detección de malware mediante visualización de imágenes. No obstante, los detalles arquitectónicos y de preprocesamiento son de alto nivel.

Criterio de Evaluación	Puntaje (0 o 1)
¿El estudio tiene una pregunta claramente definida?	1
¿Describe adecuadamente el algoritmo y los datos?	1
¿Reporta métricas de rendimiento confiables?	0
¿Analiza resultados o simplemente los menciona?	1
Puntaje Total	3

Cuadro 5.32: Evaluación de calidad del estudio: Cyber Security Threats Detection in Internet of Things Using Deep Learning Approach

6. Discusión

En esta sección se analizan y sintetizan los hallazgos principales derivados de la revisión sistemática de la literatura, con el objetivo de identificar patrones, tendencias clave, para la predicción y mitigación de amenazas cibernéticas.

6.1. Algoritmos de Machine Learning Predominantes y su Efectividad

En los estudios revisados, se identifican varios algoritmos de Machine Learning aplicados a la ciberseguridad. Los supervisados como Random Forest, SVM, Naive Bayes, Árboles de Decisión y regresión logística son los más usados, destacando Random Forest y XGBoost por su alto desempeño en clasificación y detección de amenazas.

En cuanto a algoritmos no supervisados, destacan K-Means, DBSCAN y BIRCH, principalmente para detección de anomalías y ataques de día cero. Los modelos de ensamble con boosting también mostraron muy buenos resultados frente a métodos más simples.

El Deep Learning se aplica cada vez más con arquitecturas como CNN, RNN, LSTM y GANs, logrando altos niveles de precisión, especialmente en escenarios complejos como detección de malware en IoT. GANs también se utilizan para generar ataques simulados y reforzar defensas.

Finalmente, aunque en menor medida, se exploró el aprendizaje por refuerzo con técnicas como Q-Learning y Deep Q-Networks, así como herramientas automáticas de entrenamiento.

En resumen, los modelos basados en ensambles supervisados y las redes profundas son los que muestran mayor efectividad. Sin embargo, la elección depende del tipo

de amenaza, el dataset y los recursos computacionales disponibles.

6.2. Características Más Predictivas

La literatura analizada destaca varias categorías de características como altamente predictivas:

- Características de Tráfico de Red
- Atributos de Malware y Vulnerabilidades

6.3. Conjuntos de Datos Disponibles

Varios estudios recurren a datasets públicos y bien conocidos en la comunidad, tales como KDD Cup 1999, NSL-KDD, UNSW-NB15, CIC-IDS2017, DARPA, Kyoto, y SDN20 (Halbouni et al., 2022; Abdiyeva-Aliyeva et al., 2022; Zoppi et al., 2021). Estos datos podrían ser anticuados y no representar adecuadamente el panorama de amenazas actual.

Otros trabajos optan por utilizar datasets privados o generados específicamente para el estudio. Por ejemplo: Google Code Jam y Leopard Mobile para tareas de detección de piratería de software y malware.

6.4. Métricas de Evaluación

La revisión muestra una consistencia en el uso de ciertas métricas clave:

- Accuracy, Precision, Recall (o Tasa de Detección/TPR), y F1-Score son las métricas más comúnmente reportadas en la mayoría de los estudios que implementan modelos de clasificación.
- La Tasa de Falsos Positivos (FPR) o Tasa de Falsas Alarmas (FAR).
- Error Rate.
- Loss y Validation loss.

6.5. Desafíos y Oportunidades Futuras

El campo de la ciberseguridad enfrenta varios desafíos, como la evolución constante de las amenazas y la necesidad de herramientas más proactivas. Futuras investigaciones deberían centrarse en:

- Desarrollar datasets más completos y representativos.
- Explorar técnicas avanzadas de aprendizaje profundo (deep learning) para mejorar la precisión de las predicciones.
- Establecer estándares claros para la evaluación de modelos de machine learning en ciberseguridad.

En conclusión, aunque los modelos de machine learning muestran un gran potencial para predecir amenazas cibernéticas, aún existen importantes desafíos que deben abordarse para maximizar su eficacia.

Bibliografía

- [1] Hunter Joshua, Automating Cybersecurity with Machine Learning and Predictive Analytics. <https://researchworkx.com/index.php/jci/article/view/71>
- [2] Giovanni Apruzzese, Pavel Laskov, Edgardo Montes de Oca, Wissam Mallouli, Luis Brdalo Rapa, Athanasios Vasileios Grammatopoulos, and Fabio Di Franco. 2023. The Role of Machine Learning in Cybersecurity. *Digital Threats* 4, 1, Article 8 (March 2023), 38 pages. <https://doi.org/10.1145/3545574>
- [3] Ahsan, M., Nygard, K. E., Gomes, R., Chowdhury, M. M., Rifat, N., & Connolly, J. F. (2022). Cybersecurity Threats and Their Mitigation Approaches Using Machine Learning—A Review. *Journal of Cybersecurity and Privacy*, 2(3), 527-555. <https://doi.org/10.3390/jcp2030027>
- [4] Alejandro Cervera García, Alyson Goussens, Ciberseguridad y uso de las TIC en el Sector Salud, Atención Primaria, https://www.sciencedirect.com/science/article/pii/S0212656723002871?pes=vor&getft_integrator=scopus
- [5] Camasca J. C., Gave K. P., Paredes P. J. (2024). Desarrollo de un modelo predictivo basado en técnicas de Machine Learning para la priorización de vulnerabilidades y la optimización en la etapa de mitigación de riesgos operativos de ciberseguridad [Tesis de Licenciatura, Universidad ESAN. Facultad de Ingeniería]. Repositorio Institucional Universidad ESAN. <https://hdl.handle.net/20.500.12640/4403>.
- [6] A. Halbouni, T. S. Gunawan, M. H. Habaebi, M. Halbouni, M. Kartiwi and R. Ahmad, "Machine Learning and Deep Learning Approaches for CyberSecurity:

- A Review, in IEEE Access, vol. 10, pp. 19572-19585, 2022, doi: 10.1109/ACCESS.2022.3151248.
- [7] Buuri J., Mansour S., El-Said M., Wang X. An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks (2024) <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85216032029&doi=10.1145%2f3686852.3686860&partnerID=40&md5=164d5bc6d18e6d835f28f726a06c1e27>
- [8] Mohammed Amin Almaiah, Leen Mohammad Saqr, Leen Ahmad Al-Rawwash, Layan Ahmed Altellawi, Romel Al-Ali, Omar Almomani, Classification of Cybersecurity Threats, Vulnerabilities and Countermeasures in Database Systems, Computers, Materials and Continua, 2024, <https://doi.org/10.32604/cmc.2024.057673>.
- [9] Gunay Abdiyeva-Aliyeva, Jeyhun Aliyev, Ulfat Sadigov, Application of classification algorithms of Machine learning in cybersecurity, Procedia Computer Science, Volume 215, 2022, Pages 909-919, ISSN 1877-0509, <https://doi.org/10.1016/j.procs.2022.12.093>.
- [10] F. O. Olowononi, D. B. Rawat and C. Liu, Resilient Machine Learning for Networked Cyber Physical Systems: A Survey for Machine Learning Security to Securing Machine Learning for CPS, in IEEE Communications Surveys & Tutorials, vol. 23, no. 1, pp. 524-552, Firstquarter 2021, doi: 10.1109/COMST.2020.3036778.
- [11] T. Zoppi, A. Ceccarelli and A. Bondavalli, Unsupervised Algorithms to Detect Zero-Day Attacks: Strategy and Application, in IEEE Access, vol. 9, pp. 90603-90615, 2021, doi: 10.1109/ACCESS.2021.3090957.
- [12] N. Z. Gorment, A. Selamat, L. K. Cheng and O. Krejcar, "Machine Learning Algorithm for Malware Detection: Taxonomy, Current Challenges, and Future Directions, in IEEE Access, vol. 11, pp. 141045-141089, 2023, doi: 10.1109/ACCESS.2023.3256979.
- [13] Buuri J., Mansour S., El-Said M., Wang X. An Empirical Study Using Microsoft Azure Auto Machine Learning to Detect Zero-Day Attacks, 2024, DOI:

10.1145/3686852.3686860 <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85216032029&doi=10.1145%2f3686852.3686860&partnerID=40&md5=164d5bc6d18e6d835f28f726a06c1e27>

- [14] Vera-Mundaca V.G., Aquino-Trujillo J.Y. Cybersecurity Strategies for Smart Homes: A Systematic Review of Threats and Mitigation Approaches in IoT Environments [Estrategias de Ciberseguridad para Hogares Inteligentes: Una Revisión Sistemática de Amenazas y Enfoques de Mitigación en Entornos IoT] (2024) DOI: 10.18687/LEIRD2024.1.1.307 <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85217229952&doi=10.18687%2fLEIRD2024.1.1.307&partnerID=40&md5=9d09db89f5c43c499d863b085fa39165>
- [15] M. Ozkan, E. Akin, Ö. Aslan, S. Kosunalp, T. Iliev, I Stoyanov, Ivan Beloev, A Comprehensive Survey: Evaluating the Efficiency of Artificial Intelligence and Machine Learning Techniques on Cyber Security Solutions, 2024, https://xplorestaging.ieee.org/ielx7/6287639/10380310/10403908.pdf?arnumber=10403908&getft_integrator=scopus
- [16] F. Ullah et al., Çyber Security Threats Detection in Internet of Things Using Deep Learning Approach, in IEEE Access, vol. 7, pp. 124379-124389, 2019, doi: 10.1109/ACCESS.2019.2937347.